

Descente de gradient sous contraintes

Gradient projeté et Gradient conditionnel

10 février 2020

Formalisation du problème

Problème d'optimisation convexe

$$\begin{array}{ll} \min_{\mathbf{w}} & f(\mathbf{w}) \\ \text{tel que} & \mathbf{w} \in \mathcal{X} \end{array}$$

où f est différentiable et \mathcal{X} un ensemble convexe.

Condition d'optimalité

- \mathbf{w}^* est solution du problème ssi

$$\nabla f(\mathbf{w}^*)^\top (\mathbf{y} - \mathbf{w}^*) \geq 0 \quad \forall \mathbf{y} \in \mathcal{X}$$

Projection sur un ensemble convexe

Définition

- Soit \mathcal{X} un ensemble convexe de \mathbb{R}^d , et y un point de \mathbb{R}^d , on appelle la projection de y sur \mathcal{X} , la solution du problème

$$\begin{array}{ll} \min_{\mathbf{w}} & \frac{1}{2} \|\mathbf{y} - \mathbf{w}\|_2^2 \\ \text{tel que} & \mathbf{w} \in \mathcal{X} \end{array}$$

Exemples de projection simple

- projection sur l'orthant positif
- projection sur la boule unité de norme 2

Algorithme de gradient projeté

Iteration k

$$\mathbf{w}^{k+1} = P_{\mathcal{X}}[\mathbf{w}^k - \alpha_k \nabla f(\mathbf{w}^k)]$$

où $P[\cdot]$ est l'opérateur de projection sur \mathcal{X} , et le pas $\alpha_k = \beta^{t_k}$ et t_k le premier entier positif tel que

$$f(\mathbf{w}^{k+1}) \leq f(\mathbf{w}^k) + \sigma \nabla f(\mathbf{w}^k)^\top (\mathbf{w}^{k+1} - \mathbf{w}^k)$$

Intuitions

- ▶ on réalise un pas de descente ...
- ▶ et on projette la solution sur l'ensemble admissible

Propriété

- ▶ si le problème admet une solution, alors la séquence des \mathbf{w}_{k+1} converge vers cette solution

Interprétation du Gradient projeté

Approximation quadratique

- ▶ si $f(\mathbf{w})$ est différentiable, on peut approximer f en \mathbf{w}_0 par

$$\tilde{f}(\mathbf{w}) = f(\mathbf{w}_0) + \nabla_{\mathbf{w}_0} f(\mathbf{w})^\top (\mathbf{w} - \mathbf{w}_0) + (\mathbf{w} - \mathbf{w}_0)^\top \mathbf{H}(\mathbf{w} - \mathbf{w}_0)$$

avec $\mathbf{H} = \frac{1}{2t} \mathbf{I}$

Propriété

- ▶ lien avec la descente de gradient

$$\mathbf{w}_{k+1} = \arg \min_{\mathbf{w}} \tilde{f}(\mathbf{w}) = \mathbf{w}_k - t \nabla_{\mathbf{w}_k} f$$

- ▶ lien avec le gradient projeté

$$\mathbf{w}_{k+1} = \arg \min_{\mathbf{w}} \tilde{f}(\mathbf{w}) = P_{\mathcal{X}}(\mathbf{w}_k - t \nabla_{\mathbf{w}_k} f)$$

Gradient conditionnel aka Algorithme de Franke-Wolfe

Principe

- ▶ utilise une approximation linéaire de f
- ▶ a l'itération k , on cherche un point qui vérifie

$$\mathbf{z}^{k+1} = \arg \min_{\mathbf{z} \in \mathcal{X}} \nabla_{\mathbf{w}^k} f^\top \mathbf{z}$$

\mathbf{z}^{k+1} est un point admissible qui définit une direction de descente


- ▶ l'itération est

$$\mathbf{w}^{k+1} = \mathbf{w}^k + \gamma_k (\mathbf{z}^{k+1} - \mathbf{w}^k) = (1 - \gamma_k) \mathbf{w}^k + \gamma_k \mathbf{z}^{k+1}$$

- ▶ le pas γ_k peut être optimisé mais on peut également choisir un pas par défaut :

$$\gamma_k = \frac{2}{k+1}$$

Illustration



(jaggi,2011)

Propriétés

- Utile si

$$\arg \min_{\mathbf{z} \in \mathcal{X}} \nabla_{\mathbf{w}^k} f^\top \mathbf{z}$$

est facile à calculer. C'est le cas pour les contraintes de type $\|\mathbf{w}\|_p \leq t$

- Certificat d'optimalité

$$\max_{\mathbf{z} \in \mathcal{X}} \nabla_{\mathbf{w}} f(\mathbf{w}^k)^\top (\mathbf{w}^k - \mathbf{z}) \geq f(\mathbf{w}^{k-1}) - f^*$$

- Vitesse de convergence

$$f(\mathbf{w}^{k-1}) - f^* \leq \frac{2M}{k+2}$$

où M est une constante dépendant de la courbure de f .