

Optimisation quadratique

25 février 2021

Introduction

Définition

- ▶ un problème d'optimisation quadratique générique s'écrit

$$\begin{array}{ll}\min_{\mathbf{x} \in \mathbb{R}^d} & \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{c}^\top \mathbf{x} \\ \text{sc} & \mathbf{A} \mathbf{x} = \mathbf{a} \\ & \mathbf{B} \mathbf{x} \leq \mathbf{b} \\ & \mathbf{x} \geq 0\end{array}$$

où $\mathbf{Q} \in \mathbb{R}^{d \times d}$ est une matrice symétrique et $\mathbf{A} \in \mathbb{R}^{m_1 \times d}$, $\mathbf{B} \in \mathbb{R}^{m_2 \times d}$.
Dans notre cas, on suppose que \mathbf{Q} est définie positive

- ▶ parfois on note
 - ▶ $\mathbf{A} \mathbf{x} = \mathbf{a}$ par $\mathbf{a}_i^\top \mathbf{x} = a_i$ avec $i = 1, \dots, m_1$
 - ▶ $\mathbf{B} \mathbf{x} = \mathbf{b}$ par $\mathbf{b}_j^\top \mathbf{x} = b_j$ avec $j = 1, \dots, m_2$

Application d'un problème QP

Régression quadratique parcimonieux


$$\begin{array}{ll} \min_{\mathbf{w}, t_i} & \frac{1}{2} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2 + \lambda \sum_i t_i \\ \text{sc} & -t_i \leq w_i \leq t_i \end{array}$$

Problème dual SVM

Les variables duales optimales s'obtiennent

$$\begin{array}{ll} \min_{\alpha} & \frac{1}{2} \alpha^\top \mathbf{Q} \alpha - \alpha^\top \mathbf{1} \\ \text{sc} & \alpha^\top \mathbf{y} = 0 \\ & 0 \leq \alpha_i \leq C \end{array}$$

où $Q_{i,j} = y_i y_j k(\mathbf{x}_i, \mathbf{x}_j)$



Quelques classes de QP

QP non-contraint

$$\min_{\mathbf{x} \in \mathbb{R}^d} \quad \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{c}^\top \mathbf{x}$$

QP avec contraintes de boîtes

$$\min_{\mathbf{x} \in \mathbb{R}^d} \quad \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{c}^\top \mathbf{x} \\ l_i \leq \mathbf{x}_i \leq u_i \quad \forall i$$

QP avec contraintes d'égalité

$$\min_{\mathbf{x} \in \mathbb{R}^d} \quad \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{c}^\top \mathbf{x} \\ \text{sc} \quad \mathbf{A} \mathbf{x} = \mathbf{a}$$

QP avec contraintes d'inégalité

$$\min_{\mathbf{x} \in \mathbb{R}^d} \quad \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{c}^\top \mathbf{x} \\ \text{sc} \quad \mathbf{A} \mathbf{x} = \mathbf{a} \\ \mathbf{B} \mathbf{x} \leq \mathbf{b}$$

QP non-contraint

Le problème

$$\min_{\mathbf{x} \in \mathbb{R}^d} \quad \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{c}^\top \mathbf{x}$$

Résolution

- ▶ Descente de gradient ou Méthode de Newton
- ▶ algorithme de gradient conjugué
 - ▶ algorithme trouvant un \mathbf{x}^* tel que $\mathbf{Q}\mathbf{x}^* = -\mathbf{c}$
 - ▶ <https://www.cs.cmu.edu/~quake-papers/painless-conjugate-gradient.pdf>

QP avec contraintes de boîtes

Le problème

$$\min_{\mathbf{x} \in \mathbb{R}^d} \quad \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{c}^\top \mathbf{x} \\ l_i \leq \mathbf{x}_i \leq u_i \quad \forall i$$

Cas d'usage

- ▶ Débruitage en image : $l_i = 0$ et $u_i = 255$.
- ▶ SVM sans biais

Résolution

- ▶ Algorithme de gradient projeté
- ▶ Projection sur une contrainte de boîte

$$\mathbf{x}^* = \arg \min_{\mathbf{x}} \frac{1}{2} \|\mathbf{y} - \mathbf{x}\|_2^2 \quad \text{sc} \quad l_i \leq \mathbf{x}_i \leq u_i \quad \forall i$$

$$x_i^* = y_i \text{ si } l_i \leq y_i \leq u_i, \quad x_i^* = l_i \text{ si } y_i \leq l_i \text{ et } x_i^* = u_i \text{ si } y_i \geq u_i$$

- ▶ Il existe des variantes de gradient projeté très efficace.

QP avec contraintes

Cas général

$$\begin{array}{ll} \min_{\mathbf{x} \in \mathbb{R}^d} & \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{c}^\top \mathbf{x} \\ \text{sc} & \mathbf{A} \mathbf{x} = \mathbf{a} \\ & \mathbf{x}_i \geq 0 \quad \forall i \end{array}$$

où $\mathbf{A} \in \mathbb{R}^{m \times d}$

Transformation des cas spécifiques

- ▶ les contraintes d'inégalités peuvent être prise en compte dans cette forme car $\mathbf{B} \mathbf{x} \leq \mathbf{b}$ équivaut à $\mathbf{B} \mathbf{x} + \mathbf{s} = \mathbf{b}$. On a donc un problème augmenté où les variables deviennent

$$\tilde{\mathbf{x}} = \begin{bmatrix} \mathbf{x} \\ \mathbf{s} \end{bmatrix} \quad \tilde{\mathbf{Q}} = \begin{bmatrix} \mathbf{Q} & 0 \\ 0 & 0 \end{bmatrix} \quad \tilde{\mathbf{c}} = \begin{bmatrix} \mathbf{c} \\ 0 \end{bmatrix} \quad \tilde{\mathbf{A}} = \begin{bmatrix} \mathbf{A} & 0 \\ \mathbf{B} & \mathbf{I} \end{bmatrix} \quad \tilde{\mathbf{a}} = \begin{bmatrix} \mathbf{a} \\ \mathbf{b} \end{bmatrix}$$

QP : algorithme de points intérieurs

Principe

- ▶ Utilisation d'une barrière \log pour les contraintes de positivité.
- ▶ Le problème associé devient $(BQP)_\mu$

$$\begin{array}{ll} \min_{\mathbf{x} \in \mathbb{R}_+^d} & \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{c}^\top \mathbf{x} - \mu \sum_i \log(x_i) \\ \text{sc} & \mathbf{A} \mathbf{x} = \mathbf{b} \end{array}$$

- ▶ $\mu \log(x_i)$ agit comme une pénalité pour les variables s'approchant de 0
- ▶ Lorsque μ est grand, la solution est à l'intérieur du domaine d'admissibilité défini par l'orthant positif et l'hyperplan $\mathbf{A} \mathbf{x} = \mathbf{b}$.

Lagrangien associé

$$\mathcal{L}_\mu(\mathbf{x}, \lambda) = \frac{1}{2} \mathbf{x}^\top \mathbf{Q} \mathbf{x} + \mathbf{c}^\top \mathbf{x} - \mu \sum_i \log(x_i) - \lambda^\top (\mathbf{A} \mathbf{x} - \mathbf{b})$$

QP Points intérieurs

Condition KKT associé à $(BQP)_\mu$

$$\begin{aligned}\frac{\partial \mathcal{L}_\mu}{\partial \mathbf{x}} &= 0 \Rightarrow \mathbf{Q}\mathbf{x} + \mathbf{c} - \mu \mathbf{X}^{-1} \mathbf{e} - \mathbf{A}^\top \lambda = 0 \\ \frac{\partial \mathcal{L}_\mu}{\partial \lambda} &= 0 \Rightarrow \mathbf{A}\mathbf{x} - \mathbf{b} = 0 \\ \mathbf{x} &\geq 0\end{aligned}$$

où \mathbf{e} est un vecteur de 1 et \mathbf{X}^{-1} est la matrice diagonale des $\frac{1}{x_i}$. On a des conditions de stationnarité qui sont non-linéaires.

Réécriture

- ▶ On définit $\mathbf{s} = \mu \mathbf{X}^{-1} \mathbf{e}$
- ▶ On obtient le système d'équation suivant

$$\begin{aligned}\Rightarrow \mathbf{Q}\mathbf{x} - \mathbf{s} - \mathbf{A}^\top \lambda &= -\mathbf{c} \\ \mathbf{A}\mathbf{x} &= \mathbf{b} \\ x_i s_i &= \mu \quad \forall i = 1, \dots, d\end{aligned}$$

QP méthode de points intérieurs

KKT et objectifs

- ▶ pour un $\mu > 0$ donné, les conditions *KKT* définissent un système d'équations non-linéaires.
- ▶ Soit

$$F_{\mu}(\mathbf{x}, \lambda, \mathbf{s}) = \begin{bmatrix} \mathbf{Q}\mathbf{x} + \mathbf{c} - \mathbf{s} - \mathbf{A}^{\top} \lambda \\ \mathbf{A}\mathbf{x} - \mathbf{b} \\ X\mathbf{S} - \mu\mathbf{e} \end{bmatrix}$$

où $X = \text{diag}(\mathbf{x}) \in \mathbb{R}^{d \times d}$ et $S = \text{diag}(\mathbf{s}) \in \mathbb{R}^{d \times d}$.

- ▶ les conditions KKT sont satisfaites si on trouve \mathbf{x}, λ et \mathbf{s} telles que

$$F_{\mu}(\mathbf{x}, \lambda, \mathbf{s}) = 0$$

QP méthode de points intérieurs

Problème sous-jacent

- Trouver les zeros d'une fonction multivariée

$$F_{\mu}(\mathbf{x}, \lambda, \mathbf{s}) = 0$$

Méthode de Newton-Raphson

- en 1D : soit x_k une approximation du 0 alors, x_{k+1}

$$0 = f'(x_k)(x_{k+1} - x_k) + f(x_k)$$

est une meilleure approximation

- en multivarié, on cherche \mathbf{d} telle que

$$0 = F_{\mu}(\mathbf{x}_k, \lambda_k, \mathbf{s}_k) + J_{F_{\mu}}(\mathbf{x}_k, \lambda_k, \mathbf{s}_k)\mathbf{d}_k$$

où J est la jacobienne de F et \mathbf{d}_k la direction de mise à jour.

$$\mathbf{d}_k = (\Delta \mathbf{x}_k, \Delta \lambda_k, \Delta \mathbf{s}_k) \text{ et}$$

$$(\mathbf{x}_{k+1}, \lambda_{k+1}, \mathbf{s}_{k+1}) = (\mathbf{x}_k, \lambda_k, \mathbf{s}_k) + \alpha_k(\Delta \mathbf{x}_k, \Delta \lambda_k, \Delta \mathbf{s}_k)$$

QP méthode de points intérieurs

Itération d'une méthode de point intérieur

- résolution d'un système linéaire en d défini par

$$-F_{\mu}(\mathbf{x}_k, \lambda_k, \mathbf{s}_k) = J_{F_{\mu}}(\mathbf{x}_k, \lambda_k, \mathbf{s}_k)\mathbf{d}$$

- La Jacobienne s'écrit

$$J_{F_{\mu}}(\mathbf{x}_k, \lambda_k, \mathbf{s}_k) = \begin{bmatrix} \mathbf{Q} & -\mathbf{A}^{\top} & -\mathbf{I} \\ \mathbf{A} & 0 & \mathbf{0} \\ S_k & 0 & X_k \end{bmatrix}$$

où $X_k = \text{diag}(\mathbf{x}_k) \in \mathbb{R}^{d \times d}$ et $S_k = \text{diag}(\mathbf{s}_k) \in \mathbb{R}^{d \times d}$.

- La résolution de ce système linéaire est coûteux, il faut un algorithme efficace et approprié.

QP méthode de points intérieurs

Algorithme

1. initialiser l'algorithme avec des paramètres $\mathbf{x}_0 > 0$, $\mathbf{s}_0 > 0$, $k = 0$

2. définir $\sigma_k \in [\sigma_{min}, \sigma_{max}]$, $\mu_k = \frac{\mathbf{x}_k^\top \mathbf{s}_k}{d}$

3. résoudre

$$J_{F_\mu}(\mathbf{x}_k, \lambda_k, \mathbf{s}_k) \mathbf{d} = - \begin{bmatrix} \mathbf{Q}\mathbf{x} + \mathbf{c} - \mathbf{s} - \mathbf{A}^\top \lambda \\ \mathbf{A}\mathbf{x} - \mathbf{b} \\ X\mathbf{S} - \sigma_k \mu_k \mathbf{e} \end{bmatrix}$$

pour obtenir \mathbf{d}_k

4. en partant de $\alpha = 0$, choisir le plus grand α_k tel que

$$(\mathbf{x}_k, \mathbf{s}_k) + \alpha_k (\Delta \mathbf{x}_k, \Delta \mathbf{s}_k) > 0$$

5. mise à jour

$$(\mathbf{x}_{k+1}, \lambda_{k+1}, \mathbf{s}_{k+1}) = (\mathbf{x}_k, \lambda_k, \mathbf{s}_k) + \alpha_k (\Delta \mathbf{x}_k, \Delta \lambda_k, \Delta \mathbf{s}_k)$$

6. $k = k + 1$

7. si $\frac{\mathbf{x}_k^\top \mathbf{s}_k}{d} \leq \epsilon$ retourner en 2

QP méthode de points intérieurs

Remarques

- ▶ critère de terminaison $\frac{\mathbf{x}_k^\top \mathbf{s}_k}{d} \leq \epsilon$
 - ▶ comme $\mathbf{x}^\top \mathbf{s} = d\mu$, le critère d'arrêt suppose que la barrière a de moins en moins d'influence.
- ▶ le rôle de σ_k
 - ▶ idéalement, on cherche un zéro de F_μ quand $\mu = 0$.
 - ▶ on part d'un μ donné, et on décroît le μ cible en prenant $\sigma_k \mu_k$ et $\sigma_k < 1$
 - ▶ typiquement, on prend $\sigma_k \in [0.01, 0.75]$.
- ▶ la structure de la Jacobienne peut être prise en compte pour construire un solveur de système linéaire efficace
- ▶ il faut trouver un point initial $\mathbf{x}_0, \mathbf{s}_0$ faisable